
SalmoTrace-BERT: Atribusi Sumber Genomik *Salmonella enterica* Menggunakan Fitur SNP, Frekuensi K-mer, dan Embedding DNABERT-2

Muhammad Raihaan Perdana Danendra Shafi Athallah M. Abizzar Gamadrian Kenzie Raffa Ardhana

Abstract

Mengidentifikasi asal isolat *Salmonella enterica*, apakah berasal dari rantai pangan atau bukan, merupakan tantangan utama dalam surveilans keamanan pangan berbasis genomik. Kami menyajikan SalmoTrace-BERT, sebuah pipeline Python yang melakukan atribusi sumber biner pada 168 rakit genom publik dari NCBI Pathogen Detection, menggunakan tiga representasi fitur genomik komplementer: (i) matriks SNP berbasis referensi (8.157 posisi), (ii) frekuensi pentanukleotida k-mer bebas-alignment (1.024 fitur), dan (iii) embedding kontekstual DNABERT-2 (768 dimensi). Klasifikasi dievaluasi dengan validasi silang STRATIFIEDGROUPKFOLD yang dikelompokkan berdasarkan kluster SNP NCBI untuk mencegah kebocoran data dari isolat berkerabat. Studi ablasi menunjukkan bahwa fitur k-mer mencapai macro F1 terbaik 0,655, sementara DNABERT-2 tanpa fine-tuning hanya menghasilkan F1=0,515. Perlu dicatat bahwa performa klasifikasi secara keseluruhan masih terbatas, hal ini disebabkan ukuran dataset yang relatif kecil (168 isolat) dan homogenitas genomik inherent isolat *Salmonella* publik yang membatasi daya diskriminasi sinyal genomik.

1. Pendahuluan

Salmonella enterica adalah penyebab utama penyakit bawaan makanan di seluruh dunia, bertanggung jawab atas sekitar 93 juta kasus dan 155.000 kematian setiap tahun (World Health Organization, 2023). Dalam konteks keamanan pangan, kemampuan melacak asal isolat, apakah dari rantai produksi pangan seperti ternak dan unggas, atau dari lingkungan non-rantai pangan seperti sampel klinis, merupakan fondasi investigasi wabah berbasis genomik.

Whole-genome sequencing (WGS) telah mentransformasi epidemiologi dengan menyediakan matriks *single-nucleotide polymorphism* (SNP) yang menangkap variasi genetik pada resolusi tinggi (Loman & Pallen, 2015). Alat pemanggil SNP berbasis referensi seperti Snippy (Seemann, 2015) dan BLAST+ (Camacho et al., 2009) telah menjadi standar investigasi wabah, di mana jarak Hamming berpasangan dari matriks core-SNP digunakan untuk pengelompokan hierarkis dan atribusi sumber (Achtman et al., 2012; Nguyen et al., 2020). Namun, pipeline alignment penuh bersifat mahal secara komputasi, dan daya diskriminasinya bergantung pada keragaman genomik kumpulan isolat.

Sebagai pelengkap, profil frekuensi k-mer bebas-alignment, seperti yang digunakan pada sketsa MinHash (Ondov et al., 2016), dapat menangkap sinyal komposisi nukleotida yang relevan tanpa alignment eksplisit. Di sisi lain, model bahasa DNA pra-latih DNABERT (Ji et al., 2021) dan DNABERT-2 (Zhou et al., 2023) menghasilkan embedding kontekstual 768 dimensi yang secara teoritis mengkodekan motif sekuens relevan-sumber; namun keduanya memerlukan fine-tuning pada tugas genomik hilir untuk mencapai performa kompetitif.

Perbandingan sistematis ketiga jenis representasi ini, SNP, k-mer, dan embedding, untuk atribusi sumber *Salmonella* dengan evaluasi yang ketat terhadap kebocoran data dari isolat berkerabat belum pernah dilaporkan. Penelitian ini mengisi kesenjangan tersebut. Perlu ditekankan bahwa proyek ini merupakan **simulasi forensik genomik** menggunakan 168 isolat data publik NCBI; ukuran dataset yang terbatas dan homogenitas genomik inherent isolat publik menyebabkan performa klasifikasi belum optimal, hal ini menjadi batasan eksplisit yang dibahas pada Bagian 3.

Rumusan masalah:

1. Apakah frekuensi k-mer bebas-alignment dapat menyamai atau melampaui fitur SNP untuk atribusi sumber?
2. Apakah DNABERT-2 tanpa fine-tuning memberikan informasi komplementer terhadap fitur SNP?
3. Seberapa diskriminatif pengelompokan hierarkis berba-

sis SNP untuk memisahkan isolat rantai pangan dari non-rantai pangan?

Kontribusi:

- Pipeline Python end-to-end (*SalmoTrace-BERT*) mencakup QC genom, ekstraksi SNP, komputasi k-mer, embedding DNABERT-2, dan klasifikasi multi-fitur dengan metadata AMR.
- Protokol evaluasi group-aware (StratifiedGroupKFold per kluster SNP NCBI) yang memitigasi kebocoran dari isolat berkerabat.
- Studi ablasi komparatif pada 168 genom *S. enterica* dengan interpretasi biologis dan analisis keterbatasan eksplisit.

2. Metode

2.1. Dataset dan Kontrol Kualitas

Kami mengunduh 168 rakit genom *S. enterica* (format FASTA) beserta metadata dari NCBI Pathogen Detection (National Center for Biotechnology Information, 2024). Genom referensi adalah *S. enterica* serovar Typhimurium LT2 (aksesi GCF_000006945.2). Setiap rakit dikenai tiga filter kualitas: ukuran genom 4–6 Mb, fraksi-N $\leq 5\%$, dan kontig ≤ 500 . Seluruh 168 isolat lulus QC.

Label sumber isolasi dinormalisasi dari 23 kategori mentah menjadi target biner seimbang: `food_chain_associated` (FCA) dan `non_food_chain_associated` (NFCA), masing-masing 84 isolat. Cakupan geografis mencakup 13 negara; 48% isolat berasal dari Amerika Serikat.

2.2. Ekstraksi Fitur

Matriks SNP. Pemanggilan SNP berbasis referensi dilakukan dengan pencocokan k-mer ($k=21$), menghasilkan 8.157 posisi variabel. Nukleotida dikodekan sebagai bilangan bulat (A $\rightarrow$ 0, C $\rightarrow$ 1, G $\rightarrow$ 2, T $\rightarrow$ 3) membentuk matriks 168×8.157 .

Fitur k-mer. Frekuensi pentanukleotida (5-mer) dihitung genome-wide, menghasilkan matriks 168×1.024 yang ternormalisasi dalam $[0, 1]$.

Embedding DNABERT-2. Sekuens dipotong menjadi jendela 512 bp (maks. 500 per isolat, stride 256 bp), ditokenisasi, lalu dilewatkan melalui DNABERT-2-117M (Zhou et al., 2023). Embedding per-isolat diperoleh via *masked mean pooling* atas seluruh jendela. Model digunakan sebagai ekstraktor beku tanpa fine-tuning.

Fitur AMR. Vektor biner kehadiran gen resistansi antibiotik dari metadata NCBI disertakan pada kondisi ablasi tertentu.

Attention MIL. Model *Multiple Instance Learning* berbasis atensi dilatih atas embedding per-jendela DNABERT-2, memungkinkan pembobotan jendela secara diskriminatif.

2.3. Klasifikasi dan Evaluasi

Semua klasifikasi menggunakan Random Forest (200 estimator, `random.state=42`) kecuali dinyatakan lain. Protokol utama adalah STRATIFIEDGROUPKFOLD 5-lipat dengan `snp_cluster` NCBI sebagai grup, mencegah isolat berkerabat muncul di lipatan pelatihan dan pengujian. Metrik: F1 makro, akurasi seimbang, F1 berbobot, dan silhouette score.

2.4. Gambaran Umum Pipeline

Gambar 1 mengilustrasikan alur pipeline secara keseluruhan, dari input data hingga laporan forensik.

2.5. Cuplikan Kode Utama

Berikut tiga fungsi yang menjadi inti pipeline. Kode lengkap tersedia di repositori GitHub proyek.

(1) Ekstraksi Matriks SNP (`src/snp/extractor.py`). Fungsi `build_core_snp_matrix()` membangun matriks SNP berbasis referensi menggunakan indeks k-mer vectorised dan diagonal chaining per kontig:

Listing 1. Ekstraksi matriks core-SNP berbasis referensi.

```
1 def build_core_snp_matrix(  
2     genomes, reference_seq, k=21,  
3     min_core_fraction=0.95,  
4     min_isolate_callability=0.10,  
5 ):  
6     ref_seq_up = reference_seq.upper()  
7     ref_len = len(ref_seq_up)  
8     # Bangun indeks k-mer unik dari referensi (  
9         vectorised NumPy)  
10    ref_hashes, ref_pos = _build_ref_kmer_index(  
11        ref_seq_up, k)  
12    # Alokasi matriks uint8: n_isolat x ref_len (A/T/  
13        G/C/N)  
14    matrix = np.zeros((len(genomes), ref_len), dtype=  
15        np.uint8)  
16    for i, (acc, contigs) in enumerate(genomes.items()  
17        ):  
18        _fill_isolate_row(contigs, ref_hashes,  
19            ref_pos, matrix[i], k)  
20    # Filter: core positions + remove invariant sites  
21    callable_frac = (matrix > 0).mean(axis=0)  
22    core_mask = callable_frac >= min_core_fraction  
23    snp_matrix = matrix[:, core_mask]  
24    variant_mask = snp_matrix.max(0) != snp_matrix.  
25        min(0)  
26    return pd.DataFrame(snp_matrix[:, variant_mask],  
27        index=list(genomes.keys()))
```

(2) Komputasi K-mer (`src/data/kmer.py`). Fungsi `extract_kmer_features()` menghitung frekuensi 5-mer yang ternormalisasi secara genome-wide tanpa alignment:

Listing 2. Komputasi frekuensi pentanukleotida (5-mer).




Figure 1. Alur pipeline SalmoTrace-BERT: dari input FASTA dan metadata hingga atribusi sumber forensik melalui tiga jalur ekstraksi fitur (SNP, k-mer, dan DNABERT-2).

```

1 def extract_kmer_features(genomes, k=5):
2     kmers = _all_kmers(k) # 4^k = 1024 kombinasi
3     rows = {}
4     for acc, seq in genomes.items():
5         seq_up = seq.upper()
6         counts = Counter()
7         for i in range(len(seq_up) - k + 1):
8             window = seq_up[i:i+k]
9             if all(c in "ATGC" for c in window):
10                counts[window] += 1
11            total = sum(counts.values()) or 1
12            # Normalisasi: frekuensi dalam [0, 1]
13            rows[acc] = {km: counts.get(km, 0) / total
14                        for km in kmers}
15    return pd.DataFrame(rows).T
  
```

(3) **Embedding** **DNABERT-2**
(src/embedding/encoder.py). Fungsi
embed_sequence() menghasilkan vektor 768 di-
mensi per jendela dengan *masked mean pooling* atas *hidden*
state terakhir:

Listing 3. Encoding satu jendela DNA dengan DNABERT-2.

```

1 def embed_sequence(seq, tokenizer, model, device="cpu"):
2     inputs = tokenizer(seq, return_tensors="pt",
3                       truncation=True, max_length=512)
4     input_ids = inputs["input_ids"].to(device)
5     attention_mask = inputs["attention_mask"].to(device)
6     with torch.no_grad():
7         outputs = model(input_ids)
8     hidden = outputs[0] # (1, seq_len, 768)
9     # Masked mean pooling: abaikan token padding
10    mask = attention_mask.unsqueeze(-1).float()
11    emb = (hidden * mask).sum(dim=1) \
12          / mask.sum(dim=1).clamp(min=1e-9)
13    return emb.squeeze(0).cpu().numpy() # (768,)
  
```

3. Hasil dan Diskusi

3.1. Analisis Data Eksploratif (EDA)

Sebelum klasifikasi, kami melakukan analisis eksploratif untuk memahami karakteristik dataset. Tabel 1 merangkum statistik utama.

Table 1. Statistik deskriptif dataset SalmoTrace-BERT.

Karakteristik	Nilai
Jumlah isolat total	168
Isolat FCA / NFCA	84 / 84
Jumlah negara asal	13
Proporsi isolat dari USA	48%
Posisi SNP teridentifikasi	8.157
Jarak SNP minimum antar-isolat	<10
Jarak SNP maksimum antar-isolat	993
Rata-rata jarak SNP	505,85
Jumlah kluster hierarkis (k=5)	5
Kluster SNP NCBI unik	52
Dimensi embedding DNABERT-2	768
Fitur k-mer (5-mer)	1.024

Distribusi kelas biner seimbang sempurna (84:84), menghilangkan bias mayoritas-kelas. Namun, distribusi geografis sangat tidak merata (48% dari USA), sehingga generalisasi ke populasi global terbatas. Dari 23 kategori sumber isolasi mentah, 14 kategori memiliki kurang dari 3 sampel, indikasi ketidakseimbangan kelas halus yang dapat mendestabilisasi estimasi F1 per-kelas. Rentang jarak SNP yang luas (min <10 hingga maks 993) mengindikasikan isolat dengan kekerabatan genetik sangat dekat di satu sisi dan isolat yang jauh berkerabat di sisi lain; hal ini juga menjelaskan mengapa rasio separasi kluster ($1,6\times$) tergolong rendah.

3.2. Pengelompokan Hierarkis Berbasis SNP

Pengelompokan hierarkis (average linkage) menghasilkan lima kluster (silhouette 0,284, dipilih berdasarkan inspeksi dendrogram). Rata-rata jarak SNP intra-kluster 443,1 vs. 711,0 antar-kluster menghasilkan rasio separasi $1,6\times$ yang rendah, mencerminkan rentang jarak yang sangat lebar (min <10, maks 993): pasangan klonal dan isolat jauh-berkerabat hadir bersamaan. Kluster pertama didominasi NFCA, sementara kluster tiga dan empat mencakup campuran FCA/NFCA hampir setara.

Tabel 2 menunjukkan ARI dan NMI terhadap empat kolom metadata. ARI=0,001 terhadap `snp_cluster` NCBI (52 kluster, resolusi ≈ 50 SNP) mencerminkan perbedaan granularitas: lima kluster kami merepresentasikan filogeni tingkat atas, bukan pengelompokan sumber spesifik. NMI=0,209 untuk `isolation_source` mengonfirmasi sinyal bersama yang lemah.

Meski tidak memulihkan label sumber, lima kluster ini berperan kritis sebagai *stratifikasi grup* pada Stratified-

Table 2. Validasi kluster terhadap metadata (ARI / NMI). Pengelompokan dengan hierarchical clustering average-linkage, $k = 5$.

Kolom metadata	ARI	NMI	#Kat
<code>isolation_source</code>	0,025	0,209	22
<code>serovar</code>	-0,032	0,074	3
<code>snp_cluster</code> (NCBI)	0,001	0,191	52
<code>geo_loc_name</code>	-0,020	0,161	38

Table 3. Perbandingan lengkap seluruh konfigurasi fitur dan model, StratifiedGroupKFold 5-lipat. **Cetak tebal** = terbaik. RF=RandomForest, LR=Logistic Regression, SVC=Support Vector, MIL=Attention-MIL.

Fitur	Model	F1 _{mac}	Bal.Acc	F1 _w
<i>Berbasis SNP</i>				
SNP	RF	0,634 $\pm$ 0,10	0,666	0,657
SNP	LR	0,578 $\pm$ 0,13	0,645	0,591
SNP	SVC	0,589 $\pm$ 0,11	0,618	0,621
<i>Berbasis DNABERT-2</i>				
DNABERT-2	RF	0,515 $\pm$ 0,09	0,563	0,523
DNABERT-2	LR	0,485 $\pm$ 0,04	0,518	0,502
DNABERT-2	SVC	0,472 $\pm$ 0,03	0,499	0,493
DNABERT-2	MIL	0,622	0,637	0,642
<i>Berbasis K-mer</i>				
K-mer	RF	0,655$\pm$0,09	0,676	0,674
<i>Gabungan (Hibrida)</i>				
SNP + DNABERT	RF	0,635 $\pm$ 0,10	0,665	0,660
K-mer + AMR	LR	0,589 $\pm$ 0,06	0,604	0,616
SNP + K-mer + AMR	RF	0,586 $\pm$ 0,08	0,639	0,604
<i>Baseline</i>				
AMR only	LR	0,413 $\pm$ 0,06	0,504	0,456
Dummy	—	0,282 $\pm$ 0,08	0,500	0,252

GroupKFold: isolat klonal dalam kluster yang sama dipisahkan ke lipatan berbeda, mencegah kebocoran data (lihat Bagian 3).

3.3. Studi Ablasi Atribusi Sumber

Tabel 3 merangkum seluruh 14 konfigurasi fitur-model yang dievaluasi. Semua konfigurasi melampaui baseline dummy (F1=0,282) secara substansial, namun performa tertinggi (F1=0,655) masih terbilang moderat, konsisten dengan keterbatasan dataset yang kecil dan homogenitas genomik dataset yang dibahas sebelumnya. Berikut analisis per kelompok eksperimen.

K-mer unggul. Profil frekuensi pentanukleotida mencapai macro F1 terbaik 0,655 (Bal.Acc 0,676), melampaui SNP meski tanpa alignment. Komposisi nukleotida global menangkap bias penggunaan kodon dan preferensi dinukleotida skala-genom yang berkaitan dengan adaptasi FCA secara holistik, sekaligus menjadi pilihan paling ringan secara komputasi. Standar deviasi $\pm 0,09$ konsisten di semua konfigurasi RF, mencerminkan variasi dari ukuran lipatan (≈ 33 isolat) bukan instabilitas model.

SNP kompetitif. SNP-RF mencapai F1=0,634 (hanya 0,021 di bawah k-mer). Skor silhouette SNP (0,284) jauh

lebih tinggi dari k-mer (0,103), namun keunggulan geometris ini tidak berkonversi menjadi klasifikasi lebih baik di bawah evaluasi group-aware karena isolat klonal dipisahkan oleh stratifikasi grup. RF mengungguli SVC (0,589) dan LR (0,578), mengonfirmasi struktur non-linear di ruang 8.157 dimensi.

DNABERT-2 sebagai representasi perantara. DNABERT-2 berfungsi sebagai lapisan pemrosesan representasi, bukan fitur klasifikasi langsung. Embedding beku 768 dimensi belum disesuaikan untuk sinyal sumber *Salmonella* sehingga RF langsung hanya menghasilkan $F1 = 0,515$; model linear lebih buruk lagi (LR 0,485; SVC 0,472), mengindikasikan struktur yang tidak terorganisir linear. Attention MIL yang mengagregasi embedding per-jendela (512 bp) secara selektif meningkatkan F1 ke 0,622 (+0,107), menunjukkan bahwa informasi sumber terkonsentrasi di jendela genomik tertentu yang dapat diidentifikasi mekanisme atensi.

Hibrida dan AMR. Penggabungan fitur tidak memberikan peningkatan: SNP+DNABERT (0,635) hampir identik SNP saja; K-mer+AMR (0,589) dan tiga fitur (0,586) justru lebih rendah dari K-mer tunggal karena fitur AMR memperkenalkan noise. AMR saja ($F1 = 0,413$) mengonfirmasi gen resistansi antibiotik tidak membawa sinyal sumber yang memadai. RF secara konsisten mengungguli LR dan SVC di semua kelompok fitur.

3.4. Analisis Kebocoran Data

Untuk mengkuantifikasi dampak pemisahan group-aware, kami membandingkan StratifiedGroupKFold group-aware dengan pemisahan terStratifikasi naif. Peningkatan F1 maksimum di bawah pemisahan naif adalah $\Delta F1_{\max} = +0,088$, mengonfirmasi inflasi moderat ketika isolat berkerabat bocor antar-lipatan. Semua hasil yang dilaporkan menggunakan protokol group-aware.

3.5. Interpretasi Biologis

Keunggulan fitur k-mer atas alignment berbasis SNP memiliki penjelasan biologis yang masuk akal: isolat yang berasosiasi dengan rantai pangan mungkin berbagi bias penggunaan kodon, pola komposisi GC, atau preferensi dinukleotida skala genom yang berkaitan dengan adaptasi terhadap matriks pangan kaya nutrisi dan lingkungan saluran cerna ternak. Sinyal komposisi ini ditangkap secara holistik oleh profil 5-mer, tetapi terdilusi dalam matriks SNP posisional yang jarang di mana alel spesifik pada masing-masing dari 8.157 posisi harus secara individual memprediksi sumber.

Nilai ARI yang sangat rendah (0,001) antara lima kluster hierarkis kami dan 52 kluster SNP yang ditetapkan NCBI menunjukkan bahwa pengelompokan kami menangkap tingkat

granularitas genomik yang berbeda. Kluster SNP NCBI didefinisikan pada resolusi lebih halus; menggabungkan menjadi lima grup memulihkan sinyal geografis atau filogeni luas, bukan sinyal spesifik-sumber.

4. Kesimpulan

Kami telah menyajikan SalmoTrace-BERT, sebuah pipeline multi-fitur untuk atribusi sumber biner *Salmonella enterica* dari data WGS publik. Temuan utama kami adalah:

- Profil k-mer pentanukleotida bebas-alignment ($F1 = 0,655$) sedikit mengungguli fitur SNP berbasis alignment ($F1 = 0,634$) untuk klasifikasi rantai pangan vs. non-rantai pangan, menunjukkan bahwa komposisi nukleotida global mengkodekan informasi relevan-sumber.
- DNABERT-2 berperan sebagai lapisan pemrosesan representasi perantara, bukan fitur klasifikasi primer: embedding beku 768 dimensi dari model pra-latih mengkodekan informasi kontekstual multi-spesies yang belum disesuaikan untuk sinyal sumber *Salmonella*, sehingga skor RF langsung hanya mencapai $F1 = 0,515$. Mekanisme Attention MIL yang mengagregasi embedding per-jendela secara selektif lebih efektif memanfaatkan representasi tersebut ($F1 = 0,622$), dan fine-tuning tugas-spesifik diharapkan meningkatkan kualitas representasi lebih lanjut.
- Evaluasi group-aware sangat penting: pemisahan naif menginflasi F1 hingga 0,088 akibat kebocoran keterkaitan.
- Rasio separasi genomik yang rendah ($1,6\times$) dan ARI mendekati nol terhadap kluster NCBI mencerminkan homogenitas genomik rakit *Salmonella* yang tersedia secara publik, yang membatasi performa klasifikasi absolut.

Arah penelitian selanjutnya. Fine-tuning DNABERT-2 pada data atribusi sumber *Salmonella* berlabel diharapkan dapat meningkatkan kualitas embedding secara substansial. Perluasan dataset melampaui 168 isolat, penggabungan metadata wabah epidemiologi nyata, dan validasi pada koleksi yang beragam secara geografis juga merupakan langkah penting ke depan. Integrasi dengan alignment core-SNP berbasis Snippy dapat memberikan posisi SNP yang lebih presisi dibandingkan pendekatan pencocokan k-mer yang kami gunakan.

Pernyataan Dampak

Penelitian ini bertujuan untuk memajukan metode komputasi dalam surveilans keamanan pangan berbasis genomik.

Dengan menunjukkan bahwa fitur k-mer bebas-alignment dapat menyaingi metode berbasis SNP untuk atribusi sumber, pipeline kami menurunkan hambatan komputasi untuk epidemiologi genomik di lingkungan dengan sumber daya terbatas. Semua data yang digunakan tersedia secara publik melalui NCBI; tidak ada informasi pasien pribadi yang diakses. Pipeline ini tidak dimaksudkan untuk digunakan dalam investigasi wabah resmi tanpa validasi epidemiologi independen, sebagaimana dicatat secara eksplisit dalam dokumentasi keterbatasan kami.

Perangkat Lunak dan Data

Kode dan dokumentasi pipeline tersedia di GitHub. Dataset diperoleh dari NCBI Pathogen Detection (<https://www.ncbi.nlm.nih.gov/pathogens/>). Check-point model DNABERT-2 tersedia secara publik di Hugging Face (zhihan1996/DNABERT-2-117M).

References

- Achtman, M., Wain, J., Weill, F.-X., Nair, S., Zhou, Z., Sangal, V., Browning, M. F., Bhatti, M. M., Kiiru, J., et al. Multilocus sequence typing as a replacement for serotyping in *Salmonella enterica*. *PLOS Pathogens*, 8 (6):e1002776, 2012.
- Camacho, C., Coulouris, G., Avagyan, V., Ma, N., Papadopoulos, J., Bealer, K., and Madden, T. L. BLAST+: architecture and applications. *BMC Bioinformatics*, 10 (1):421, 2009.
- Ji, Y., Zhou, Z., Liu, H., and Davuluri, R. V. DNABERT: pre-trained bidirectional encoder representations from transformers model for DNA-language in genome. *Bioinformatics*, 37(15):2112–2120, 2021.
- Loman, N. J. and Pallen, M. J. Twenty years of bacterial genome sequencing. *Nature Reviews Microbiology*, 13 (12):787–794, 2015.
- National Center for Biotechnology Information. NCBI pathogen detection isolates browser. <https://www.ncbi.nlm.nih.gov/pathogens/>, 2024.
- Nguyen, M. T., Baker, K., Le, T. D., Pham, H. A., Phat, V. V., et al. Whole-genome sequencing of *Salmonella* for source attribution in food safety investigations. *Frontiers in Microbiology*, 11:1669, 2020.
- Ondov, B. D., Treangen, T. J., Melsted, P., Mallonee, A. B., Bergman, N. H., Koren, S., and Phillippy, A. M. Mash: fast genome and metagenome distance estimation using MinHash. *Genome Biology*, 17(1):132, 2016.
- Seemann, T. Snippy: fast bacterial variant calling from NGS reads. *GitHub Repository*, 2015.
- World Health Organization. *Salmonella (non-typhoidal): Fact sheet*. WHO Media Centre, 2023.
- Zhou, Z., Ji, Y., Li, W., Dutta, P., Davuluri, R. V., and Liu, H. DNABERT-2: Efficient foundation model and benchmark for multi-species genome. *arXiv preprint arXiv:2306.15006*, 2023.